



**Escuela Superior
de Ingeniería y Tecnología**
Universidad de La Laguna

Trabajo de Fin de Grado

Predicción de series temporales mediante técnicas de aprendizaje profundo

Time series forecasting using deep learning techniques

José Ramón Morera Campos

La Laguna, 16 de mayo de 2025

D. **Leopoldo Acosta Sánchez**, profesor Catedrático de Universidad adscrito al Departamento de Nombre del Departamento de la Universidad de La Laguna, como tutor

D. **Daniel Acosta Hernández**, profesor Titular de Universidad adscrito al Departamento de Nombre del Departamento de la Universidad de La Laguna, como cotutor

C E R T I F I C A N

Que la presente memoria titulada:

"Predicción de series temporales mediante técnicas de aprendizaje profundo"

ha sido realizada bajo su dirección por D. **José Ramón Morera Campos**.

Y para que así conste, en cumplimiento de la legislación vigente y a los efectos oportunos firman la presente en La Laguna a 16 de mayo de 2025

Agradecimientos

XXXXX

Licencia



© Esta obra está bajo una licencia de Creative Commons Reconocimiento-NoComercial-CompartirIgual 4.0 Internacional.

Resumen

XXXXX

Palabras clave: XXXXXX, XXXX, XXXX

Abstract

XXXXX

Keywords: XXXX, XXXX, XXXX

Índice general

1. Introducción	1
1.1. Motivación del proyecto	1
1.2. Planteamiento	1
1.3. Antecedentes y estado del arte	2
1.4. Objetivos	2
2. Adquisición y preprocesado de datos	4
2.1. Fuentes de los datos	4
2.2. Proceso de adquisición y almacenamiento	5
2.2.1. Flujos de adquisición de Grafcan	5
2.2.2. Flujos de adquisición de Open-Meteo	6
2.2.3. Almacenamiento	6
2.3. Preprocesado	7
2.3.1. Visualización	7
2.3.2. Manejo de datos faltantes	9
2.3.3. Selección de modelo de Open-Meteo	9
2.3.4. Detección de valores anómalos	10
2.3.5. Exploración de frecuencias - Dominio de Fourier	11
2.3.6. Codificación de la información temporal	13
2.3.7. Estudio de correlación	13
2.4. Creación de ventanas de datos	14
2.4.1. Implementación	14
2.4.2. Normalización	16
3. Modelos de predicción	17
3.1. Primera sección de este capítulo	17
3.2. Segundo apartado de este capítulo	17
3.3. Tercer apartado de este capítulo	17
4. Despliegue	18
5. Conclusiones y líneas futuras	19
6. Summary and Conclusions	20
7. Presupuesto	21
7.1. Sección Uno	21
A. Título del Apéndice 1	22

A.1. Algoritmo XXX	22
A.2. Algoritmo YYY	22
A.3. Algoritmo ZZZ	23

B. Título del Apéndice 2 24

B.1. Otro apéndice: Sección 1	24
B.2. Otro apéndice: Sección 2	24

Índice de Figuras

2.1. Mapa de las estaciones climatológicas Grafcan empleadas.	5
2.2. Flujo de adquisición de datos de Grafcan en node-red.	6
2.3. Flujo de adquisición de datos de Open-Meteo en node-red.	7
2.4. Visualización de la presión atmosférica en Arona durante 2023.	8
2.5. Visualización de la temperatura del aire en Arona durante 2024.	8
2.6. Visualización de la humedad relativa en Arona durante 2025.	9
2.7. Histograma de la humedad relativa en Arona.	10
2.8. Histograma de la temperatura del aire en Arona.	11
2.9. Distancias media de los K vecinos más cercanos para la temperatura del aire en Arona.	11
2.10Histograma de la humedad relativa en Arona con outliers detectados con knn. 12	
2.11Histograma de la temperatura del aire en Arona con outliers detectados con knn.	12
2.12Transformada rápida de Fourier de la temperatura del aire en Arona.	12
2.13Transformada rápida de Fourier de la presión atmosférica en Arona.	13
2.14Mapa de correlación entre las variables del dataset.	13
2.15Pseudocódigo Creación de Ventanas de Datos	15

Índice de Tablas

2.1. Datos faltantes por estación y fuente de datos (en horas)	9
2.2. Modelo de Open-Meteo seleccionado para cada variable y estación	10
7.1. Resumen de tipos	21

Capítulo 1

Introducción

1.1. Motivación del proyecto

La predicción de series temporales es un campo de estudio que ha cobrado gran relevancia en los últimos años, especialmente en el ámbito del aprendizaje automático y el aprendizaje profundo. La capacidad de anticipar eventos futuros a partir de datos históricos es fundamental en diversas áreas, como la economía, la meteorología, la salud y la ingeniería.

El campo de la meteorología, en particular, ha aumentado su relevancia en los últimos años debido al aumento de fenómenos climáticos extremos y su impacto en la sociedad. Prever con antelación la evolución de variables meteorológicas no solo permite planificar recursos, sino también contribuir a la prevención de desastres naturales.

En este contexto, el uso de redes neuronales ha demostrado ser una herramienta poderosa para abordar problemas complejos de predicción. Gracias a los avances en capacidad de cómputo y la disponibilidad de grandes volúmenes de datos, arquitecturas como LSTM, GRU y Transformers se han consolidado como soluciones de alto rendimiento. Estas redes no solo capturan patrones temporales de manera eficiente, sino que también pueden adaptarse dinámicamente a cambios en el comportamiento de la serie, mejorando la precisión y la robustez de las predicciones.

1.2. Planteamiento

En este trabajo se pretende emplear mediciones de múltiples estaciones meteorológicas de la isla de Tenerife con el fin de desarrollar un modelo de predicción climatológica a corto plazo. Se busca que dicho modelo sea capaz de generalizar más allá de las estaciones de entrenamiento. Esto es, que a partir de mediciones meteorológicas de cualquier origen, el modelo sea capaz de generar predicciones a corto plazo (3, 6 o 12 horas) de gran calidad. Se deciden considerar 3 variables meteorológicas: temperatura, humedad y presión atmosférica. La elección de estas variables se basa en su relevancia para la predicción del clima y la existencia de registros en las estaciones meteorológicas de Tenerife.

Se establece un especial énfasis en el tratamiento de los datos, estudiándose exhaustivamente diversas técnicas.

La idea principal pasa por la creación de ventanas de información, que son secuencias de datos consecutivos agrupados

Como parte del trabajo se contempla el despliegue de una infraestructura tecnológica

que permita la captura y el procesamiento de datos públicos, así como la creación y evaluación de diversos modelos predictivos que extraigan información valiosa a partir de estos datos.

Para ello, se empleará el lenguaje de programación Python, que ofrece una amplia gama de bibliotecas y herramientas para el análisis de datos y la implementación de modelos de aprendizaje automático.

Así mismo, se plantea desplegar los modelos en un entorno de producción, permitiendo su uso en aplicaciones prácticas. De esta forma, cualquier usuario podrá suministrar mediciones de la variable que desee durante las últimas horas y obtener un pronóstico.

1.3. Antecedentes y estado del arte

El uso de redes neuronales y técnicas de deep learning (aprendizaje profundo) para la predicción de series temporales tiene sus orígenes en la década de 1940. Aunque el término deep learning ha ganado relevancia en los últimos años, los conceptos fundamentales y algunas de las técnicas más empleadas han existido desde hace mucho tiempo, evolucionando y perfeccionándose con el avance de la tecnología. En 1943, Warren McCulloch y Walter Pitts fueron pioneros en desarrollar un modelo computacional para redes neuronales [1], estableciendo las bases de lo que hoy conocemos como inteligencia artificial basada en redes neuronales. Más adelante, en 1949, Donald Hebb introdujo la famosa Teoría Hebbiana, una hipótesis que proponía un mecanismo de aprendizaje basado en la plasticidad neuronal [2]. Este principio se aplicó a modelos computacionales, impulsando la investigación en la simulación del aprendizaje humano.

En 1958, Frank Rosenblatt avanzó en este campo con la creación del perceptrón [3], un algoritmo pionero de reconocimiento de patrones basado en una red de aprendizaje de computadora de dos capas. Este modelo simple operaba mediante operaciones de adición y sustracción, sentando las bases para el desarrollo de redes neuronales más complejas. Durante las siguientes décadas, la investigación en redes neuronales experimentó un estancamiento debido a limitaciones técnicas y a la falta de métodos eficaces para el entrenamiento de redes con múltiples capas. Sin embargo, en 1982, un gran avance revitalizó este campo: la introducción del algoritmo de propagación hacia atrás (backpropagation) [4], que resolvía el problema del entrenamiento eficiente de redes neuronales profundas, permitiendo la formación de redes multicapa de manera más rápida y eficaz. Desde entonces, las redes neuronales han continuado evolucionando, impulsadas en gran parte por los avances en la potencia de cálculo de las GPU y el desarrollo del deep learning. Hoy en día, esta tecnología es fundamental y revolucionaria, capaz de realizar predicciones de series temporales con notable rapidez y precisión. La investigación en este ámbito sigue siendo prolífica. Una búsqueda rápida en internet revela la continua producción de proyectos y estudios enfocados en perfeccionar las técnicas de predicción temporal mediante aprendizaje profundo. Estos trabajos se caracterizan por un análisis exhaustivo y la exploración de nuevos métodos, todos con el objetivo de optimizar la precisión y la eficacia de las previsiones en aplicaciones prácticas.

1.4. Objetivos

1. Evaluar y seleccionar una fuente de datos.

2. Evaluar y seleccionar el framework de aprendizaje profundo a usar en el proyecto.
3. Diseño e implementación de la metodología de procesamiento de los datos.
4. Evaluación y selección de arquitecturas pertinentes al problema.
5. Implementación de una arquitectura adecuada.
6. Evaluación del rendimiento de la solución propuesta.
7. Comparación frente a metodologías tradicionales.
8. Despliegue de la solución en un entorno de producción.

Capítulo 2

Adquisición y preprocesado de datos

Se desea trabajar con series temporales sobre mediciones climatológicas. En concreto, se eligen las variables de temperatura del aire, humedad relativa y presión atmosférica en la superficie. Dichas variables son estudiadas con frecuencia horaria, en el intervalo comprendido entre el 1 de marzo de 2023 y el 28 de febrero de 2025.

Es relevante el uso de datos en un período múltiplo del año, para asegurar que se capturan las variaciones estacionales y que el conjunto de datos está suficientemente equilibrado.

2.1. Fuentes de los datos

Se han empleado 2 fuentes para recopilar las mediciones:

- **Grafcan:** Cartográfica de Canarias, S.A. es una empresa pública de la Comunidad Autónoma de Canarias. Dispone de una red de estaciones meteorológicas cuyas mediciones son accesibles mediante una API REST de acceso gratuito previa solicitud de una clave[5].
- **Open-Meteo:** API pública de código abierto que proporciona datos de múltiples proveedores de meteorología. Este servicio no dispone de estaciones de medición propias, sino que recopila pronósticos de diferentes modelos de predicción climatológica.

Se emplea la API de predicciones pasadas[6]. Se seleccionan los modelos ICON Global del servicio meteorológico alemán (DWD) y el modelo ARPEGE Europe de Météo-France. Ambos modelos se actualizan cada 3 horas. Se explora la posibilidad de emplear las predicciones del modelo HAROME de la AEMET, pero no están disponibles de forma pública

Se eligen 4 ubicaciones de la isla de Tenerife con distintas características climáticas para el conjunto de entrenamiento y evaluación:

- **San Cristóbal de La Laguna 1 (A):** La Cuesta, 35 metros de altitud.
- **San Cristóbal de La Laguna 2 (B):** La Punta del Hidalgo, 54m.
- **La Orotava (C):** Camino de Chasna, 812m.
- **Arona (D):** Punta de Rasca, 25m.

Así mismo, se escogen 2 ubicaciones para el conjunto de test, nunca vistas en el ajuste del modelo:

- **Garachico (E):** La Montañeta, 922 m.
- **Santa Cruz de Tenerife (F):** Polígono Costa Sur, 92m.

Las ubicaciones han sido elegidas al contar con estaciones de medición de Grafcan. Sus posiciones se muestran en la Figura 2.1, con la letra indicada en la lista. Se señalan en rojo las estaciones de entrenamiento y en naranja las de test.




Figura 2.1: Mapa de las estaciones climatológicas Grafcan empleadas.

Inicialmente se valoró emplear las estaciones correspondientes a Los Cristianos, Santiago del Teide o la Punta de Teno, pero fueron descartadas por dos motivos: se detectó que existían períodos prolongados con datos faltantes en las mediciones de Grafcan. Algunas de ellas también exhibían poca correlación entre las mediciones del servicio Grafcan y las de Open-Meteo, lo que podría afectar la calidad de los datos.

2.2. Proceso de adquisición y almacenamiento

Para automatizar la adquisición de datos, se emplea la herramienta de orquestación node-red, que permite crear flujos de información mediante nodos que realizan tareas específicas o ejecutan código de JavaScript. En dicha herramienta se desarrollan dos paneles, uno para cada fuente de datos. Así mismo, dentro de cada panel se desarrollan dos flujos, uno para la adquisición de datos en un intervalo dado, y otro para la adquisición de datos en tiempo real, en particular, se establece la recogida de datos cada 6 horas.

2.2.1. Flujos de adquisición de Grafcan

Debido al funcionamiento de la API de Grafcan, se debe realizar una llamada para obtener la serie temporal de cada variable meteorológica de cada estación. Posteriormente,

se unen las series de cada estación en una única serie, que se almacena en una base de datos PostgreSQL. Este flujo está reflejado en la figura 2.2.

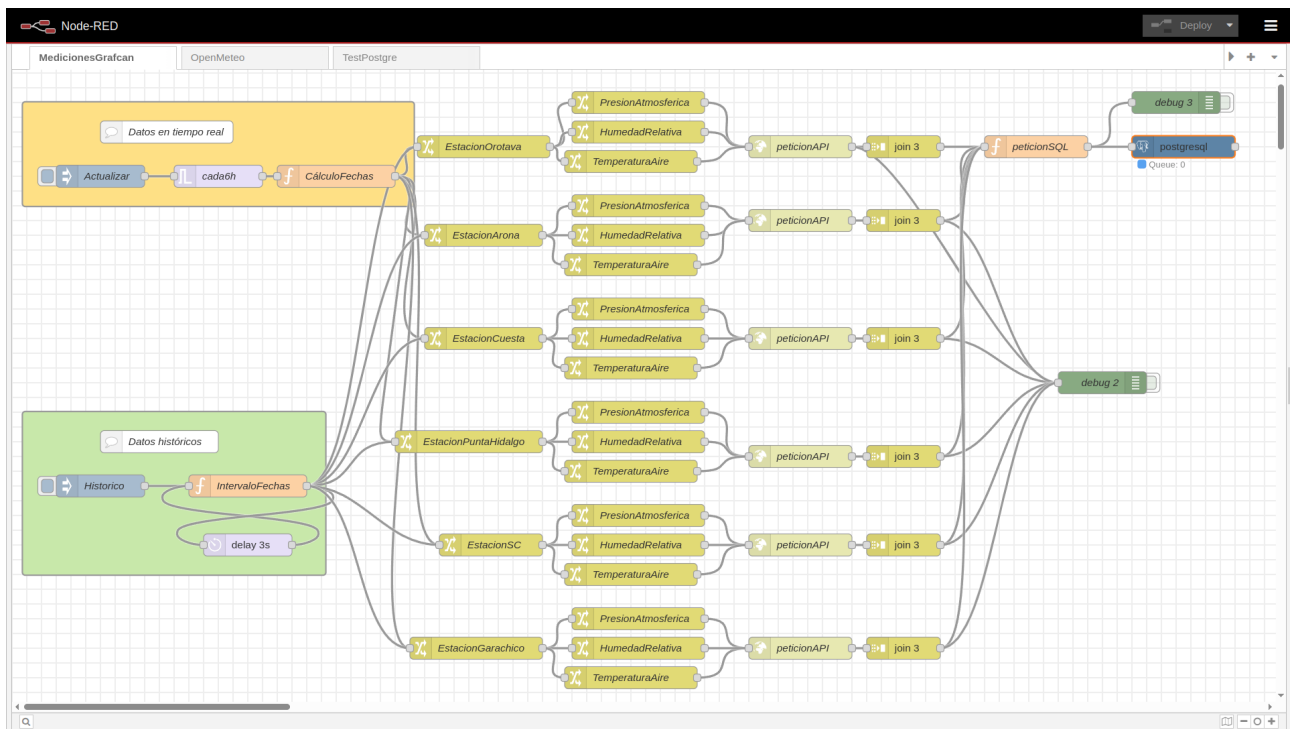


Figura 2.2: Flujo de adquisición de datos de Grafcan en node-red.

Las mediciones de Grafcan se recogen aproximadamente cada 10 minutos, si bien la frecuencia no es consistente y en ocasiones es mayor. Así mismo, los instantes de medición son independientes entre las variables estudiadas. Para manejar esta variabilidad, en este nivel los datos se agregan cada 10 minutos, usando la media de las mediciones del intervalo.

2.2.2. Flujos de adquisición de Open-Meteo

Existe una rama para obtener los datos del modelo ICON y otra para el modelo ARPEGE. Se establecen las coordenadas de cada ubicación como las de la estación de Grafcan seleccionada y se realiza una llamada a la API por cada localización y cada modelo, como se observa en la figura 2.3. Los resultados se almacenan en una base de datos PostgreSQL.

2.2.3. Almacenamiento

Se estudian distintas alternativas para el almacenamiento de los datos. Se opta por emplear TimescaleDB, una extensión del popular sistema PostgreSQL de bases de datos relacionales, especialmente adaptada para el manejo de series temporales.

Se establece un servidor TimescaleDB en un contenedor Docker. Se configura una tabla para cada estación y cada fuente: Grafcan, Open-Meteo ICON y Open-Meteo ARPEGE. Cada tabla emplea como índice y clave primaria la fecha y hora de la medición, así como su zona horaria. Las otras columnas se corresponden a la temperatura media del aire en grados Celsius, la humedad relativa en porcentaje y la presión atmosférica en superficie medida en hPa.

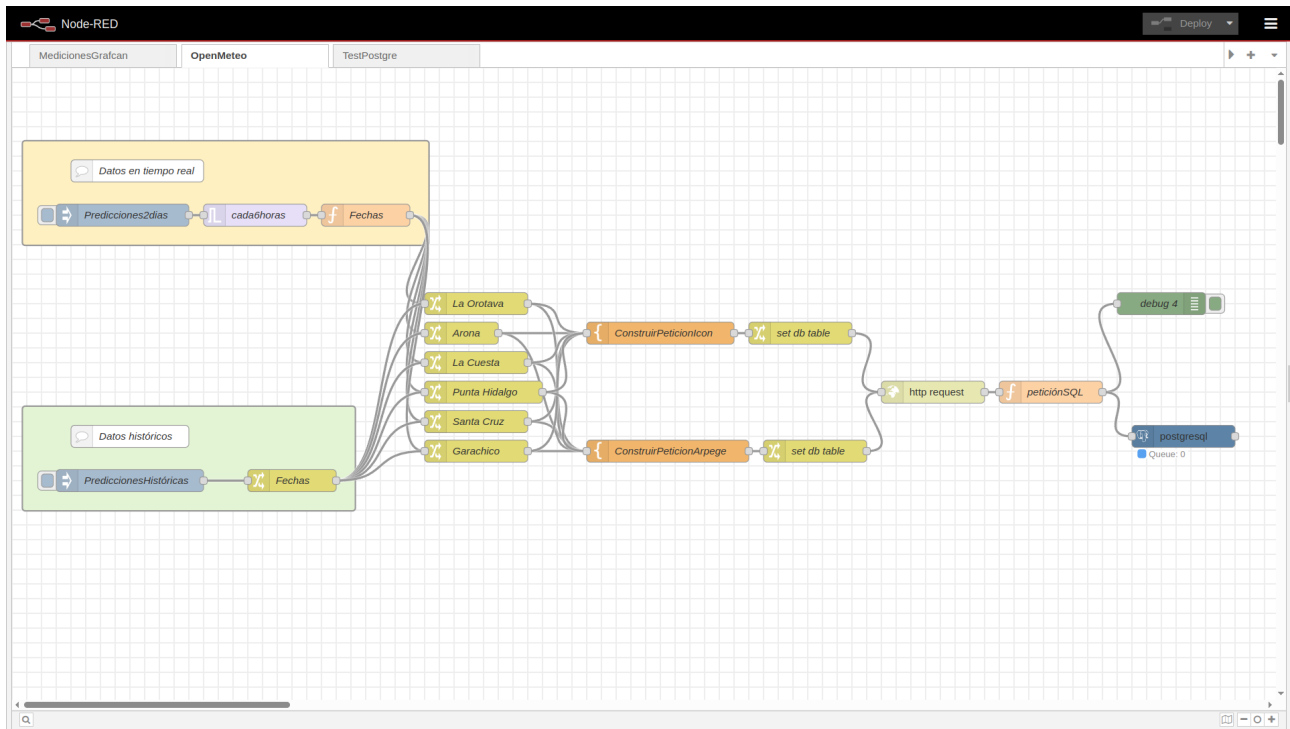


Figura 2.3: Flujo de adquisición de datos de Open-Meteo en node-red.

Es importante señalar que las mediciones de Grafcan y Open-Meteo codifican las horas en UTC, en vez de la hora local, puesto que UTC es independiente a los cambios de horario y de esta forma se mantiene la consistencia de los datos.

2.3. Preprocesado

Se desarrolla un cuaderno de Jupyter para realizar el preprocesado de los datos. El proceso descrito en este apartado se aplica de forma separada para cada estación.

En primer lugar, se obtienen las series temporales de las 3 fuentes, Grafcan y los dos modelos de Open-Meteo, para el período entre el 1 de marzo de 2023 y el 28 de febrero de 2025. Se agregan los datos con frecuencia horaria mediante la media.

Nota: En la estación de Garachico, usada para el test, el período empleado es del 1 de marzo de 2024 al 28 de febrero de 2025, puesto que el período de 2023 tiene un gran número de datos faltantes.

2.3.1. Visualización

Se visualizan los datos de cada variable para cada año. Podemos ver ejemplos en las figuras 2.4, 2.5 y 2.6.

Se observa claramente que en la presión atmosférica las mediciones de todas las fuentes son muy similares. Sin embargo, en la temperatura del aire y la humedad relativa se aprecian diferencias entre las distintas fuentes.

Cabe destacar que en la variable de humedad relativa se observa una gran variabilidad entre los datos de las distintas fuentes, que se constatará más adelante.




Figura 2.4: Visualización de la presión atmosférica en Arona durante 2023.




Figura 2.5: Visualización de la temperatura del aire en Arona durante 2024.




Figura 2.6: Visualización de la humedad relativa en Arona durante 2025.

2.3.2. Manejo de datos faltantes

Se detectan los datos faltantes para cada fuente. Las estadísticas se muestran en la tabla 2.1. Es reseñable que el modelo ICON no muestra datos faltantes, mientras que el modelo ARPEGE tiene 35 horas faltantes consecutivas, en el período entre el 31 de diciembre de 2023 y el 1 de enero de 2024.

Estación	Grafcan	Open-Meteo ICON	Open-Meteo ARPEGE
La Laguna 1 (La Cuesta)	47	0	35
La Laguna 2(La Punta del Hidalgo)	30	0	35
La Orotava	3	0	35
Arona	17	0	35
Garachico	5	0	0
Santa Cruz de Tenerife	0	0	46

Tabla 2.1: Datos faltantes por estación y fuente de datos (en horas)

Se decide imputar los datos faltantes mediante un método híbrido: si una secuencia de datos faltantes es menor a 5 horas se emplea un método de interpolación cúbica por tramos denominado PCHIP[7], que preserva la forma de los datos y evita oscilaciones indeseadas. Si la secuencia de datos faltantes es mayor a 5 horas, se copian los datos del día anterior en las mismas horas. Este tipo de imputación es común en el ámbito de las series temporales [8].

Los datos sintéticos son etiquetados como tales para poder ser identificados posteriormente.

2.3.3. Selección de modelo de Open-Meteo

Para cada variable se selecciona el modelo de Open-Meteo que mejor se ajusta a los datos de Grafcan. Se emplean diversas métricas: los coeficiente de correlación de Pearson,




Figura 2.7: Histograma de la humedad relativa en Arona.

Spearman y Kendall, así como el error cuadrático medio (MSE) y la distancia euclídea. Se elige el modelo que mejor resultados da en la mayoría de indicadores. Los resultados se muestran en la tabla 2.2.

Estación	Temperatura del aire	Presión atmosférica	Humedad relativa
La Laguna 1	ICON	ARPEGE	ICON
La Laguna 2	ARPEGE	ARPEGE	ARPEGE
La Orotava	ICON	ARPEGE	ICON
Arona	ICON	ARPEGE	ICON
Garachico	ICON	ICON	ICON
Santa Cruz de Tenerife	ICON	ARPEGE	ICON

Tabla 2.2: Modelo de Open-Meteo seleccionado para cada variable y estación

Observamos que, en general, el modelo ICON es el que mejor se ajusta a las variables de temperatura del aire y humedad relativa, mientras que el modelo ARPEGE es el que mejor se ajusta a la presión atmosférica.

Resulta reseñable señalar que la diferencia entre los modelos de Open-Meteo y Grafcan es mucho mayor en la variable de humedad relativa que en las otras. Esto puede ser relevante más adelante, de cara al rendimiento de los modelos de predicción.

Tras seleccionar el modelo de Open-Meteo para cada variable, se crea un dataset unificado con las 3 variables. De esta forma se dispone de un dataset de Open-Meteo y otro de Grafcan con las 3 variables para cada estación.

2.3.4. Detección de valores anómalos

Para la detección de valores anómalos, en primer lugar se emplea el método del rango intercuartílico (IQR). Sin embargo, se observa en los histogramas que la distribución de los datos no es puramente gaussiana, existiendo sesgos y colas largas. Por ejemplo, en la figura 2.7 se observa que la humedad presenta un sesgo a la izquierda, mientras que en la figura 2.8 se observa que la temperatura presenta una cola larga a la derecha.

Por esto, se decide emplear como método de detección de anomalías el de los K vecinos más cercanos (KNN), una alternativa robusta que permite detectar anomalías en distribuciones no gaussianas [9].

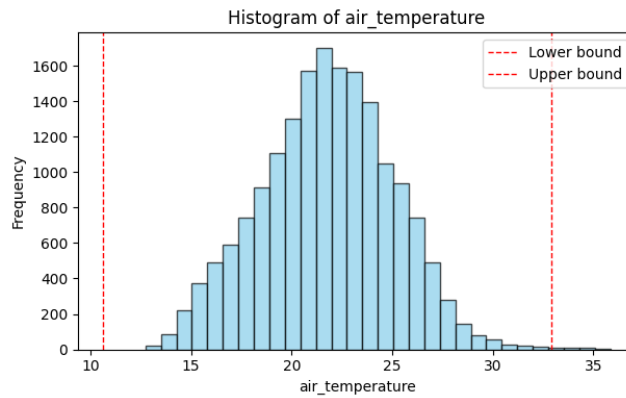


Figura 2.8: Histograma de la temperatura del aire en Arona.




Figura 2.9: Distancias media de los K vecinos más cercanos para la temperatura del aire en Arona.

Se aplica el método de KNN a cada variable por separado, con $k=10$ y límite de distancia 4 veces la desviación típica. Los valores anómalos son etiquetados como tales para poder ser identificados posteriormente. Se pueden observar ejemplos de las distancias en la figura 2.9. En las figuras 2.10 y 2.11 se muestran ejemplos de los valores anómalos detectados.

Nota: Se muestran los valores anómalos independientemente de la variable respecto a la que se detectaron.

2.3.5. Exploración de frecuencias - Dominio de Fourier

Se realiza un análisis de Fourier para cada variable. De esta forma, se pueden observar las frecuencias dominantes en los datos. Este análisis es relevante para detectar las frecuencias a emplear en la codificación de la información temporal, que se aborda en el siguiente apartado.

Se emplea la transformada rápida de Fourier (FFT), se filtran las frecuencias positivas, se acota a las frecuencias mayores a 10^{-3} (unos 16,66... minutos) y se grafican haciendo uso de escala logarítmica en el eje X. Se pueden observar ejemplos en las figuras 2.12, y 2.13. Se señalan las 5 frecuencias de mayor magnitud con un punto en rojo.

En la temperatura y humedad destacan las frecuencias de 24 y 8772 horas, correspondiente esta última a 365,5 días, lo que es razonable considerando que de los 2 años de datos, uno es bisiesto. Respecto a la presión atmosférica, la más relevante es la de 12

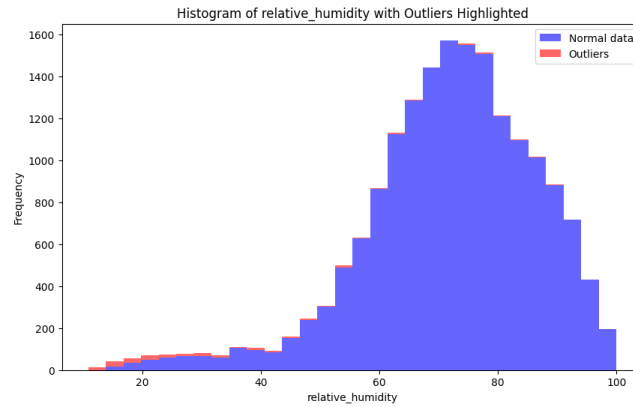


Figura 2.10: Histograma de la humedad relativa en Arona con outliers detectados con knn.




Figura 2.11: Histograma de la temperatura del aire en Arona con outliers detectados con knn.




Figura 2.12: Transformada rápida de Fourier de la temperatura del aire en Arona.




Figura 2.13: Transformada rápida de Fourier de la presión atmosférica en Arona.




Figura 2.14: Mapa de correlación entre las variables del dataset.

horas, algo debido a la naturaleza de esta variable, que presenta este ciclo debido a un fenómeno conocido como mareas térmicas [10]. Así mismo, la presión también presenta un pico en la frecuencia anual y la de medio año.

2.3.6. Codificación de la información temporal

Se decide codificar la información temporal mediante el uso de senos y cosenos de las frecuencias dominantes. En base a los resultados del análisis de Fourier, se emplean la frecuencia de 24 horas y del año, teniendo especial cuidado para detectar si el año es bisiesto o no. De esta forma, se añaden 4 variables adicionales al dataset: sin(día), cos(día), sin(año) y cos(año).

Se estudia la frecuencia semanal, pero se descarta al existir poca correlación.

2.3.7. Estudio de correlación

Se estudia la correlación entre las distintas variables que conforman el dataset mediante una matriz de correlación con el coeficiente de Pearson. Se observa que las variables climáticas tienen una correlación de entorno a 0.3, lo que indica una correlación baja 2.14.

2.4. Creación de ventanas de datos

Para la predicción de series temporales, los modelos neuronales requieren como entrada los valores de las variables en un número de instantes, en nuestro caso horas, previos, que denominaremos P . Así mismo, se define un número de horas a predecir, que denominaremos N . De esta forma, un modelo requiere P horas de datos para predecir N horas futuras. Esto es lo que se conoce como ventana de datos.

En su versión más simple, la univariable, consta de una componente X , los valores de las variables en P pasos, y una componente Y , un vector de tamaño N con los valores a predecir. No obstante, puede ser relevante incluir información adicional exógena sobre los valores a predecir, como la codificación temporal (o en otros dominios, si el día es festivo, etc).

De esta forma, optamos por contruir ventanas de datos con 3 componentes, X e Y , ya definidas, así como F , formada por las 4 variables de codificación temporal para cada paso a predecir N . Empíricamente comprobamos que la inclusión de esta información adicional mejora ligeramente el rendimiento del modelo.

En la práctica, estas ventanas se construyen mediante la técnica de ventana deslizante, que consiste en recorrer la serie temporal desplazando la ventana de datos en un número de pasos, que denominaremos S . Establecemos $S=6$ para que la ventana se desplace cada 6 horas, con el fin de evitar la redundancia de datos.

Como datos pasados empleamos la variable meteorológica estudiada, así como las restantes como covariables. Se comprueba exógenamente que añadir estas covariables mejora el rendimiento del modelo. También se emplea como datos pasados las variables de codificación temporal.

De esta forma, una ventana tiene X de tamaño $P * 7$, Y de tamaño N y F de tamaño $N * 4$.

2.4.1. Implementación

En primer lugar, se define una función `df_raw_windows` que recibe como parámetros:

- `df`: un dataframe de pandas, que es una estructura de datos de python similar a una tabla, correspondiente a un dataset de una ubicación,
- `P`: el número de pasos pasados.
- `N`: el número de pasos a predecir.
- `S`: el número de pasos a desplazar la ventana.
- `past_features`: un array con los nombres de las variables usadas como entradas.
- `future_features`: un array con los nombres de las variables exógenas usadas como datos futuros.
- `target`: el nombre de la variable objetivo a predecir.

La función devuelve un objeto con 3 atributos, `past_variables`, `future_variables` e `y`. Siendo cada uno un arreglo con los datos de cada componente de las ventanas de datos. Es decir, la ventana i ésima está formada por los i ésimos elementos de cada uno de los 3 atributos. Esta estructura se debe al comportamiento de las librerías de

los modelos de aprendizaje profundo empleados, que procesan los datos de forma más eficiente en este formato, como se verá más adelante.

El comportamiento de la función principal es el siguiente:

Pseudocódigo Creación de Ventanas de Datos

```
1: train_data = {}
2: test_data = {}
3: Para cada variable objetivo v:
4:   Para cada ubicación u:
5:     location_data = []
6:     Para cada dataset d en la ubicación u:
7:       ventanas = df_raw_windows()
8:       location_data.añadir(ventanas)
9:       windows_count = len(location_data[0][y])
10:      overlap_windows = ceil((past_n + future_n)/step)
11:      test_indexes = random_sample(windows_count, test_percent)
12:      forbidden = set()
13:      Para cada index en test_indexes:
14:        # forbid index itself and the next 'overlap_windows - 1' windows
15:        Para cada j en rango(overlap_windows):
16:          forbidden.add(index + j)
17:      train_indexes = rango(windows_count) - forbidden
18:      Para cada dataset d in location_data:
19:        past_variables_windows = location_data[d]["past_variables"]
20:        future_variables_windows = location_data[d]["future_variables"]
21:        y_windows = location_data[d]["z"]
22:        # Gather train/test splits
23:        train_past_variables = [past_variables_windows[i] for i in train_indexes]
24:        train_future_variables = [future_variables_windows[i] for i in train_indexes]
25:        train_y = [y_windows[i] for i in train_indexes]
26:        test_past_variables = [past_variables_windows[i] for i in test_indexes]
27:        test_future_variables = [future_variables_windows[i] for i in test_indexes]
28:        test_y = [y_windows[i] for i in test_indexes]
29:        train_data[v]["past_variables"].extender(train_past_variables)
30:        train_data[v]["future_variables"].extender(train_future_variables)
31:        train_data[v]["y"].extender(train_y)
32:        test_data[v]["past_variables"].extender(test_past_variables)
33:        test_data[v]["future_variables"].extender(test_future_variables)
34:        test_data[v]["y"].extender(test_y)
```

Figura 2.15: Pseudocódigo Creación de Ventanas de Datos

Para cada ubicación se eligen los índices de las ventanas de test aleatoriamente. Estos índices son los mismos para los dos datasets de una localización, puesto que los datos son bastante similares entre ambos y queremos evitar el filtrado de información. Cabe destacar la consideración de ventanas "prohibidas", que se descartan

del conjunto de entrenamiento para evitar filtrar datos. De esta forma, todas las ventanas previas que estén solapadas con una ventana de test son descartadas.

2.4.2. Normalización

Se utilizan las ventanas del conjunto de entrenamiento para calcular las características de la normalización. Usamos la estandarización o normalización Z-score, que consiste en restar la media y dividir por la desviación típica. De esta forma, los datos quedan centrados en 0 y con una desviación típica de 1.

Debemos almacenar los parámetros de normalización puesto que serán necesarios para tratar cualquier dato que se suministre en el futuro al sistema.

Capítulo 3

Modelos de predicción

Los capítulos intermedios servirán para cubrir los siguientes aspectos: antecedentes, problemática o estado del arte, objetivos, fases y desarrollo del proyecto.

Bla, Bla, Bla,

3.1. Primera sección de este capítulo

3.2. Segundo apartado de este capítulo

3.3. Tercer apartado de este capítulo

Capítulo 4

Despliegue

Los capítulos intermedios servirán para cubrir los siguientes aspectos: antecedentes, problemática o estado del arte, objetivos, fases y desarrollo del proyecto.

El capítulo 1 se describió bla, bla, bla . . .

Capítulo 5

Conclusiones y líneas futuras

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir unas conclusiones y unas líneas de trabajo futuro

Capítulo 6

Summary and Conclusions

This chapter is compulsory. The memory should include an extended summary and conclusions in english.

Capítulo 7

Presupuesto

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir un presupuesto.

7.1. Sección Uno

Tipos	Descripción
AAAA	BBBB
CCCC	DDDD
EEEE	FFFF
GGGG	HHHH

Tabla 7.1: Resumen de tipos

Apéndice A

Título del Apéndice 1

A.1. Algoritmo XXX

```
/* **** */
*
* Fichero .h
*
* **** */
*
* AUTORES
*
*
* FECHA
*
*
* DESCRIPCION
*
*
* **** */
```

A.2. Algoritmo YYY

```
/* **** */
*
* Fichero .h
*
* **** */
*
* AUTORES
*
*
* FECHA
*
*
* DESCRIPCION
*
*
* **** */
```


A.3. Algoritmo ZZZ

```
/******  
*  
* Fichero .h  
*  
*****  
*  
* AUTORES  
*  
* FECHA  
*  
* DESCRIPCION  
*  
*  
*****/
```

Apéndice B

Título del Apéndice 2

B.1. Otro apéndice: Sección 1

texto

B.2. Otro apéndice: Sección 2

texto

Bibliografía

- [1] McCulloch, W. S., & Pitts, W. (1943). *A logical calculus of the ideas immanent in nervous activity*. Bulletin of Mathematical Biophysics, 5(4), 115–133. <https://doi.org/10.1007/BF02478259>
- [2] Hebb, D. O. (1949). *The organization of behavior: A neuropsychological theory*. Wiley.
- [3] Rosenblatt, F. (1958). *The perceptron: A probabilistic model for information storage and organization in the brain*. Psychological Review, 65(6), 386–408. <https://doi.org/10.1037/h0042519>
- [4] Werbos, P. J. (1982). *Applications of advances in nonlinear sensitivity analysis*. R. F. Drenick & F. Kozin (Eds.), *System Modeling and Optimization* (Vol. 38, pp. 762–770). Springer-Verlag. <https://doi.org/10.1007/BFb0006203>
- [5] Cartográfica de Canarias, S.A. *Sistema de Observación Meteorológica de Canarias* [Sitio web]. Recuperado el 12 de mayo de 2025, de <https://sensores.grafcan.es/>
- [6] Open-Meteo *Historical Forecast API* [Sitio web]. Recuperado el 12 de mayo de 2025, de <https://open-meteo.com/en/docs/historical-forecast-api>
- [7] Fritsch, F. N., & Carlson, R. E. (1980). *Monotone piecewise cubic interpolation*. SIAM Journal on Numerical Analysis, 17(2), 238–246. <https://doi.org/10.1137/0717021>
- [8] Tawakuli, A., Havers-Zulka, B., Gulisano, V., & Kaiser, D. (2024). *Survey: Time-series data preprocessing: A survey and an empirical analysis*. Journal of Engineering Research. Advance online publication. <https://doi.org/10.1016/j.jer.2024.02.018>
- [9] Gu, X., Akoglu, L., & Rinaldo, A. (2019). *Statistical analysis of nearest neighbor methods for anomaly detection*. Advances in Neural Information Processing Systems, 32 (pp. 10921–10931). Curran Associates, Inc. <https://doi.org/10.48550/arXiv.1907.03813>
- [10] Chapman, S., & Lindzen, R. S. (1970). *Atmospheric Tides*. D. Reidel Publishing Company. <https://doi.org/10.1007/978-94-010-3399-2>