



**Escuela Superior
de Ingeniería y Tecnología**
Universidad de La Laguna

Trabajo de Fin de Grado

Predicción de series temporales mediante técnicas de aprendizaje profundo

Time series prediction using deep learning techniques

José Ramón Morera Campos

La Laguna, 11 de mayo de 2025

D. **Leopoldo Acosta Sánchez**, profesor Catedrático de Universidad adscrito al Departamento de Nombre del Departamento de la Universidad de La Laguna, como tutor

D. **Daniel Acosta Hernández**, profesor Titular de Universidad adscrito al Departamento de Nombre del Departamento de la Universidad de La Laguna, como cotutor

C E R T I F I C A N

Que la presente memoria titulada:

"Predicción de series temporales mediante técnicas de aprendizaje profundo"

ha sido realizada bajo su dirección por D. **José Ramón Morera Campos**.

Y para que así conste, en cumplimiento de la legislación vigente y a los efectos oportunos firman la presente en La Laguna a 11 de mayo de 2025

Agradecimientos

XXXXX

Licencia



© Esta obra está bajo una licencia de Creative Commons Reconocimiento-NoComercial-CompartirIgual 4.0 Internacional.

Resumen

XXXXX

Palabras clave: XXXXXX, XXXX, XXXX

Abstract

XXXXX

Keywords: XXXX, XXXX, XXXX

Índice general

1. Introducción	1
1.1. Motivación del proyecto	1
1.2. Planteamiento	1
1.3. Antecedentes y estado del arte	1
1.4. Objetivos	2
2. Adquisición y preprocesado de datos	3
2.1. Fuentes de los datos	3
2.2. Proceso de adquisición	3
3. Modelos de predicción	5
3.1. Primera sección de este capítulo	5
3.2. Segundo apartado de este capítulo	5
3.3. Tercer apartado de este capítulo	5
4. Título del Capítulo 4	6
5. Conclusiones y líneas futuras	7
6. Summary and Conclusions	8
7. Presupuesto	9
7.1. Sección Uno	9
A. Título del Apéndice 1	10
A.1. Algoritmo XXX	10
A.2. Algoritmo YYY	10
A.3. Algoritmo ZZZ	11
B. Título del Apéndice 2	12
B.1. Otro apéndice: Sección 1	12
B.2. Otro apéndice: Sección 2	12

Índice de Figuras

2.1. Mapa de las estaciones climatológicas Grafcan empleadas. 4

Índice de Tablas

7.1. Resumen de tipos 9

Capítulo 1

Introducción

1.1. Motivación del proyecto

La predicción de series temporales es un campo de estudio que ha cobrado gran relevancia en los últimos años, especialmente en el ámbito del aprendizaje automático y el aprendizaje profundo. La capacidad de anticipar eventos futuros a partir de datos históricos es fundamental en diversas áreas, como la economía, la meteorología, la salud y la ingeniería. En este contexto, el uso de redes neuronales ha demostrado ser una herramienta poderosa para abordar problemas complejos de predicción.

El campo de la meteorología, en particular, ha aumentado su relevancia en los últimos años debido al creciente aumento de fenómenos climáticos extremos y su impacto en la sociedad.

As shown in [1], the results are promising.

1.2. Planteamiento

En este trabajo se pretende emplear datos de múltiples estaciones de medición de la isla de Tenerife con el fin de desarrollar un modelo de predicción climatológica capaz de generalizar más allá de las estaciones de entrenamiento. Se establece un especial énfasis en el tratamiento de los datos, estudiándose exhaustivamente diversas técnicas y alternativas.

Este trabajo consiste en el despliegue de una infraestructura tecnológica para la captura y el procesamiento de datos públicos, junto con el diseño, desarrollo y validación de un modelo predictivo que permita extraer información valiosa a partir de dichos datos. Este enfoque integrará tanto aspectos técnicos relacionados con la gestión y el análisis de datos como la aplicación de técnicas predictivas basadas en modelos de aprendizaje automático, con el fin de optimizar y automatizar la toma de decisiones en un contexto específico.

1.3. Antecedentes y estado del arte

El uso de redes neuronales y técnicas de deep learning para la predicción de series temporales tiene sus orígenes en la década de 1940. Aunque el término deep learning ha ganado relevancia en los últimos años, los conceptos fundamentales y algunas de las técnicas más empleadas han existido desde hace mucho tiempo, evolucionando y

perfeccionándose con el avance de la tecnología. En 1943, Warren McCulloch y Walter Pitts fueron pioneros en desarrollar un modelo computacional para redes neuronales, estableciendo las bases de lo que hoy conocemos como inteligencia artificial basada en redes neuronales. Más adelante, en 1949, Donald Hebb introdujo la famosa Teoría Hebiana, una hipótesis que proponía un mecanismo de aprendizaje basado en la plasticidad neuronal. Este principio se aplicó a modelos computacionales, impulsando la investigación en la simulación del aprendizaje humano.

En 1958, Frank Rosenblatt avanzó en este campo con la creación del perceptrón, un algoritmo pionero de reconocimiento de patrones basado en una red de aprendizaje de computadora de dos capas. Este modelo simple operaba mediante operaciones de adición y sustracción, sentando las bases para el desarrollo de redes neuronales más complejas. Durante las siguientes décadas, la investigación en redes neuronales experimentó un estancamiento debido a limitaciones técnicas y a la falta de métodos eficaces para el entrenamiento de redes con múltiples capas. Sin embargo, en 1982, un gran avance revitalizó este campo: la introducción del algoritmo de propagación hacia atrás (back-propagation), que resolvía el problema del entrenamiento eficiente de redes neuronales profundas, permitiendo la formación de redes multicapa de manera más rápida y eficaz. Desde entonces, las redes neuronales han continuado evolucionando, impulsadas en gran parte por los avances en la potencia de cálculo de las GPU y el desarrollo del deep learning. Hoy en día, esta tecnología es fundamental y revolucionaria, capaz de realizar predicciones de series temporales con notable rapidez y precisión. La investigación en este ámbito sigue siendo prolífica. Una búsqueda rápida en internet revela la continua producción de proyectos y estudios enfocados en perfeccionar las técnicas de predicción temporal mediante aprendizaje profundo. Estos trabajos se caracterizan por un análisis exhaustivo y la exploración de nuevos métodos, todos con el objetivo de optimizar la precisión y la eficacia de las previsiones en aplicaciones prácticas.

1.4. Objetivos

1. Evaluar y seleccionar una fuente de datos.
2. Evaluar y seleccionar el framework de aprendizaje profundo a usar en el proyecto.
3. Diseño e implementación de la metodología de procesamiento de los datos.
4. Evaluación y selección de arquitecturas pertinentes al problema.
5. Implementación de una arquitectura adecuada.
6. Evaluación del rendimiento de la solución propuesta.
7. Comparación frente a metodologías tradicionales.
8. Despliegue de la solución en un entorno de producción.

Capítulo 2

Adquisición y preprocesado de datos

Se desea trabajar con series temporales sobre mediciones climatológicas. En concreto, se eligen las variables de temperatura del aire, humedad ambiental y presión atmosférica en la superficie. Dichas variables son estudiadas con periodicidad horaria, en el intervalo comprendido entre el 1 de marzo de 2023 y el 28 de febrero de 2025.

2.1. Fuentes de los datos

Se han empleado 2 fuentes para recopilar las mediciones:

- **Grafcan:** Cartográfica de Canarias, S.A. es una empresa pública de la Comunidad Autónoma de Canarias.
- **Open-Meteo:** API pública de código abierto que proporciona datos de múltiples servicios de meteorología.

Se eligen 3 ubicaciones de la isla de Tenerife con distintas características climáticas:

- **San Cristóbal de La Laguna:** La Cuesta, 35 metros de altitud.
- **La Orotava:** Camino de Chasna, 812 m.
- **Arona:** Punta de Rasca, 25m.

Dichas ubicaciones han sido elegidas al contar con estaciones de medición de Grafcan. Sus posiciones se muestran en la Figura 2.1, señaladas en rojo. De izquierda a derecha: Arona, La Orotava y San Cristóbal de La Laguna.

Inicialmente se valoró emplear la estación correspondiente a Los Cristianos, en vez de la de Arona, pero se detectó que existía un período prolongado con datos faltantes, por lo que fue descartada.

2.2. Proceso de adquisición

Se estudian distintas alternativas para el almacenamiento de los datos. Se opta por emplear TimescaleDB, una extensión del popular sistema PostgreSQL de bases de datos relacionales, especialmente adaptada para el manejo de series temporales.




Figura 2.1: Mapa de las estaciones climatológicas Grafcan empleadas.

Capítulo 3

Modelos de predicción

Los capítulos intermedios servirán para cubrir los siguientes aspectos: antecedentes, problemática o estado del arte, objetivos, fases y desarrollo del proyecto.

Bla, Bla, Bla,

3.1. Primera sección de este capítulo

3.2. Segundo apartado de este capítulo

3.3. Tercer apartado de este capítulo

Capítulo 4

Título del Capítulo 4

Los capítulos intermedios servirán para cubrir los siguientes aspectos: antecedentes, problemática o estado del arte, objetivos, fases y desarrollo del proyecto.

El capítulo 1 se describió bla, bla, bla . . .

Capítulo 5

Conclusiones y líneas futuras

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir unas conclusiones y unas líneas de trabajo futuro

Capítulo 6

Summary and Conclusions

This chapter is compulsory. The memory should include an extended summary and conclusions in english.

Capítulo 7

Presupuesto

Este capítulo es obligatorio. Toda memoria de Trabajo de Fin de Grado debe incluir un presupuesto.

7.1. Sección Uno

Tipos	Descripción
AAAA	BBBB
CCCC	DDDD
EEEE	FFFF
GGGG	HHHH

Tabla 7.1: Resumen de tipos

Apéndice A

Título del Apéndice 1

A.1. Algoritmo XXX

```
/******  
*  
* Fichero .h  
*  
*****  
*  
* AUTORES  
*  
*  
* FECHA  
*  
*  
* DESCRIPCION  
*  
*  
*****/
```

A.2. Algoritmo YYY

```
/******  
*  
* Fichero .h  
*  
*****  
*  
* AUTORES  
*  
* FECHA  
*  
*  
* DESCRIPCION  
*  
*  
*****/
```

A.3. Algoritmo ZZZ

```

/*****
 *
 * Fichero .h
 *
 *****/
 *
 * AUTORES
 *
 * FECHA
 *
 * DESCRIPCION
 *
 *****/

```

Apéndice B

Título del Apéndice 2

B.1. Otro apéndice: Sección 1

texto

B.2. Otro apéndice: Sección 2

texto

Bibliografía

[1] Smith, J., *A Study on LaTeX*, Journal of Typesetting, 2023.